

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

KOMPILÁTOR DATALOGU S FUNKČNÝMI
SYMBOLMI DO RELAČNEJ ALGEBRY
BAKALÁRSKA PRÁCA

2026
MATÚŠ DUCHYŇA

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

KOMPILÁTOR DATALOGU S FUNKČNÝMI
SYMBOLMI DO RELAČNEJ ALGEBRY

BAKALÁRSKA PRÁCA

Študijný program: Informatika
Študijný odbor: Informatika
Školiace pracovisko: Katedra informatiky
Školiteľ: doc. Mgr. Tomáš Plachetka, Dr.

Bratislava, 2026
Matúš Duchyňa



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Matúš Duchyňa
Študijný program: informatika (Jednoodborové štúdium, bakalársky I. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: bakalárska
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Kompilátor Datalogu s funkčnými symbolmi do relačnej algebry
Compiler of Datalog with function symbols to relational algebra

Anotácia: Definovať rozšírenie Datalogu o funkčné symboly. Skonstruovať vhodnú formálnu gramatiku v syntaxi ANTLR. Implementovať kompilátor do relačnej algebry. Integrovať s kompilátorom relačnej algebry. Overiť funkčnosť na vhodných vstupoch.

Vedúci: doc. Mgr. Tomáš Plachetka, Dr.
Katedra: FMFI.KI - Katedra informatiky
Vedúci katedry: prof. RNDr. Martin Škoviera, PhD.

Spôsob prístupnosti elektronickej verzie práce:
archív

Dátum zadania: 21.10.2025

Dátum schválenia: 27.10.2025

doc. RNDr. Dana Pardubská, CSc.
garant študijného programu

.....
študent

.....
vedúci práce

Čestné vyhlásenie: Čestne vyhlasujem, že celú bakalársku prácu na tému „Kompilátor Datalogu s funkčnými symbolmi do relačnej algebry“, vrátane všetkých jej príloh a obrázkov, som vypracoval/vypracovala samostatne, a to s použitím literatúry uvedenej v priloženom zozname.

Abstrakt

Táto práca sa zaoberá návrhom a implementáciou kompilátora z jazyka Datalog rozšíreného o funkčné symboly a vstavané predikáty do relačnej algebry. Motiváciou je integrácia Datalogu ako vyššieho dotazovacieho jazyka do experimentálneho databázového systému, ktorý používa relačnú algebru ako interný dotazovací jazyk.

V teoretickej časti práce definujeme syntax a sémantiku Datalogu s funkčnými symbolmi a vstavanými predikátmi. Následne špecifikujeme cieľovú relačnú algebru so štyrmi operátormi: **UNION**, **JOIN**, **ANTIJOIN** a **REC**.

V implementačnej časti popíšeme gramatiku Datalogu zapísanú v nástroji ANTLR 4, konštruovanie abstraktného syntaktického stromu a viacstupňový algoritmus prekladu. Kompilátor vykonáva syntaktickú aj sémantickú analýzu vstupného programu a generuje ekvivalentný výraz relačnej algebry. Výsledný nástroj je použiteľný samostatne, nezávisle od konkrétneho databázového systému.

Kľúčové slová: Datalog, relačná algebra, kompilátor, funkčné symboly, ANTLR, databázový systém

Abstract

This thesis deals with the design and implementation of a compiler from the Datalog language extended with function symbols and built-in predicates to relational algebra. The motivation is the integration of Datalog as a higher-level query language into an experimental database system that uses relational algebra as its internal query language.

In the theoretical part of the thesis, we define the syntax and semantics of Datalog with function symbols and built-in predicates. We then specify the target relational algebra with four operators: **UNION**, **JOIN**, **ANTIJOIN** and **REC**.

In the implementation part, we describe the Datalog grammar written in ANTLR 4, the construction of an abstract syntax tree, and a multi-step translation algorithm. The compiler performs syntactic and semantic analysis of the input program and generates an equivalent relational algebra expression. The resulting tool can be used standalone, independently of any specific database system.

Keywords: Datalog, relational algebra, compiler, function symbols, ANTLR, database system

Obsah

Úvod	1
1 Datalog	3
1.1 Definície	3
1.2 Rozšírenie Datalogu o funkčné symboly	6
1.3 Vstavane predikáty	7
1.4 Syntax rozšíreného Datalogu	8
1.5 Sémantika Datalogu	9
2 Relačná algebra	13
2.1 Učebnicová relačná algebra	13
2.2 Naša relačná algebra	17
2.2.1 Vstavane operátory	19
2.3 Inklúzia medzi učebnicovou a našou relačnou algebrou	20
3 Kompilátor	23
3.1 ANTLR	23
3.1.1 Rýchlokurz formálnych jazykov	23
3.1.2 Syntaktická analýza	24
3.2 Gramatika Datalogu pre ANTLR	29
3.3 Algoritmus prekladu	32
3.3.1 Generácia AST	32
3.3.2 Preklad do relačnej algebry	35
Záver	43
Literatúra	45
Príloha	47

Úvod

Klasické moderné databázové systémy poskytujú používateľom na vytváranie dotazov zväčša deklaratívne jazyky, ako napríklad SQL. Výhodou deklaratívneho jazyka je to, že používateľ sa nemusí zaoberať samotným algoritmom, ktorý vypočíta výsledok dotazu. Súčasťou klasických databázových modelov je tzv. *optimalizér*. Tento komponent s pomocou rôznych metadát o databáze vytvorí zo SQL dotazu *vykonávací plán*, t.j. algoritmus výpočtu dotazu. Avšak optimalizér nie vždy vytvorí *optimálny* vykonávací plán. Prinútiť databázový systém používať konkrétny vykonávací plán nie je niekedy jednoduché. Existujú experti, ktorí sa zaoberajú výlučne touto problematikou. Klasické postupy optimalizácie zahŕňajú používanie *hintov*, prepisovanie dotazu na iný ekvivalentný dotaz alebo explicitné nariadenie použitia konkrétneho plánu. Vykonávacie plány však väčšinou používajú operácie s množstvom parametrov a bez kvalitnej dokumentácie. Kvôli tomu je vytváranie konkrétneho plánu nepraktické a neefektívne.

Náš databázový systém¹ používa ako dotazovací jazyk relačnú algebru. Konkrétne ide o relačnú algebru so štyrmi operátormi a podporou funkčných symbolov. Viac o nej je uvedené v kapitole 2. Relačná algebra nám priamo umožňuje špecifikovať výpočet dotazu. *Loader*² z relačnej algebry do programovacieho jazyka Java a implementáciu jednotlivých funkcií v jazyku Java vytvorili kolegovia Biriukova [2] a Magát [4].

Relačná algebra je síce silným nástrojom na určenie presného algoritmu výpočtu dotazu, ale pre bežného používateľa je príliš nízkoúrovňová. Tvorba zložitejších dotazov vyžaduje manuálne skladanie operátorov, čo zvyšuje nečitateľnosť kódu a riziko chyby. Tu vzniká priestor pre Datalog, deklaratívny dotazovací jazyk založený na matematickej logike. Datalog umožňuje efektívne definovať zložité dotazy pomocou pravidiel, ktoré sú často omnoho stručnejšie ako ekvivalentné zápisy v SQL alebo relačnej algebre.

Cieľom mojej bakalárskej práce je pridať Datalog s funkčnými symbolmi ako ďalší dotazovací jazyk do nášho systému. Konkrétne ide o vytvorenie kompilátora z Datalogu do relačnej algebry tak, aby bol použiteľný aj samostatne, bez väzby na konkrétny databázový systém. Dôležité bude spracovanie funkčných symbolov, ktoré sa v štandardnom Datalogu (resp. prologu) nevyskytujú. Kompilátor musí byť schopný overiť

¹Pod *naším* databázovým systémom myslím experimentálny systém, na ktorom pracuje môj študent a kolegovia pod jeho vedením

²Kompilátor

syntaktickú a sémantickú správnosť Datalogového programu a následne vygenerovať čo najefektívnejší ekvivalentný kód v relačnej algebre.

Podobným softvérom je *Soufflé* [9]. Soufflé kompilátor taktiež vykonáva sémantickú kontrolu, ale následne preloží kód Datalogu do tzv. *Relation Algebra Machine*. Z RAM sa potom vygeneruje vysoko optimalizovaný a paralelizovaný C++ kód. Naše riešenie sa nezameriava na rýchlosť behu preloženého dotazu, ale na jeho jednoduchosť. Náš Datalog aj relačná algebra obsahujú iba tie najdôležitejšie komponenty, ale zároveň zachovávajú dotazovaciu silu.

Zásadným rozdielom oproti nášmu riešeniu je, že Soufflé nepodporuje funkčné symboly v podobe, ktorú by sme potrebovali. Soufflé nepodporuje ani priame využívanie vstavaných operátorov databázy (*built-in operators*), čo obmedzuje jeho schopnosť spolupracovať s existujúcimi databázovými systémami. Náš prístup naopak počíta so vstavanou podporou operátorov priamo v relačnej algebre a databáze, čo umožňuje vyjadriť komplexné transformácie dát v dotazoch.

Okrem výberu cieľovej platformy (C++ vs. Java) je dôležitá aj miera abstrakcie vygenerovanej relačnej algebry. Naša relačná algebra je blízka matematickým východiskám. To zvyšuje čitateľnosť dotazov a umožňuje prípadné manuálne zmeny vo výstupnom pláne výpočtu.

Práca je rozdelená na tri časti. V kapitole 1 bližšie popisujeme Datalog ako jazyk logiky a definujeme jeho rozšírenie o funkčné symboly. Pri snahe osamostatniť náš kompilátor od databázového systému sme identifikovali požiadavky na relačnú algebru. Všetky zmeny³ a ich odôvodnenia sú popísané v kapitole 2. V záverečnej kapitole 3 popisujeme samotný kompilátor, jeho jednotlivé časti vrátane gramatiky Datalogu a algoritmu prekladu.

³Oproti relačnej algebre definovanej v [2]

Kapitola 1

Datalog

1.1 Definície

V nasledujúcej kapitole formálne definujeme Datalog vo forme, v akej s ním budeme vo zvyšku práce pracovať. Definície sú inšpirované [3].

Poznámka 1.1.1. $\top$ označuje pravdu (hodnotu *true*). $\perp$ označuje nepravdu (hodnotu *false*). $\mathbb{U}$ označuje hodnotu *unknown*.

Definícia 1.1.1. *n*-árna relácia r je definovaná ako $r \subseteq D_1 \times D_2 \times \dots \times D_n$. Jednotlivé prvky relácie r nazývame **tuples**, **záznamy** alebo **usporiadané *n*-tice**. Jednotlivým zložkám *n*-tíc hovoríme **atribúty** relácie. Množinám $D_1, D_2, \dots, D_n$ sa hovorí **domény** (alebo **typy**) atribútov relácie r .

Definícia 1.1.2. Jazyk logiky pozostáva z

1. predikátových symbolov
2. symbolov pre premenné
3. symbolov pre konštanty (reprezentujú prvky z domén)
4. logických symbolov ($\wedge, \neg$)
5. symbolov všeobecných kvantifikátorov ($\forall$)
6. symbolov pre definície ($\Rightarrow$)
7. čiarok (,)
8. zátvoriek ((,))

Definícia 1.1.3. Do **formúl** patria:

1. *atomické formuly* $p(t_1, t_2, \dots, t_n)$, kde p je *n*-árny predikát a $t_1, t_2, \dots, t_n$ sú konštanty alebo premenné
2. ak A a B sú formuly, tak potom aj $A \wedge B$ a $\neg A$ sú formuly
3. nič iné formulou nie je.

Definícia 1.1.4. $A \Rightarrow B$ je **implikácia**, ak A je formula a B je atomická formula.

Definícia 1.1.5. $\forall X\iota$ sa nazýva **kvantifikovaná implikácia**, kde X je premenná a ι je implikácia. Ak je kvantifikovaná každá premenná v kvantifikovanej implikácii, nazývame ju **klauzula**.

Definícia 1.1.6. $K_1 \wedge K_2 \wedge \dots \wedge K_n$ nazývame **teóriou**, kde $K_1, K_2, \dots, K_n$ sú klauzuly.

Definícia 1.1.7. Ohodnotenie premenných je funkcia, ktorá priradí každej premennej konštantu. Ohodnotenie o , ktoré premennej X_i priradí konštantu k_i (pre $i \leq n$) označujeme $o(X_1|k_1, \dots, X_n|k_n)$. Keď vo formule A resp. implikácii ι resp. teórii $K_1 \wedge \dots \wedge K_n$ nahradíme všetky premenné podľa ohodnotenia o , výslednú formulu označujeme ako $A[o]$ resp. $\iota[o]$ resp. $K_1 \wedge \dots \wedge K_n[o]$.

Definícia 1.1.8. Interpretácia jazyka je funkcia, ktorá každej atomickej formule priradí jednu z hodnôt $\top, \perp, \Psi$.

Definícia 1.1.9. Nech $\mathcal{I}$ je interpretácia jazyka, φ je formula a o je ohodnotenie premenných. Potom $\mathcal{I} \models_{\top} \varphi[o]$ resp. $\mathcal{I} \models_{\perp} \varphi[o]$ resp. $\mathcal{I} \models_{\Psi} \varphi[o]$ označuje, že formula $\varphi[o]$ je pravdivá resp. nepravdivá resp. *unknown* vzhľadom na interpretáciu jazyka $\mathcal{I}$.

Pravdivosť formuly definujeme nasledovne:

1. $\mathcal{I} \models_{\top} \neg\varphi[o]$ ak $\mathcal{I} \models_{\perp} \varphi[o]$
 $\mathcal{I} \models_{\perp} \neg\varphi[o]$ ak $\mathcal{I} \models_{\top} \varphi[o]$
 $\mathcal{I} \models_{\Psi} \neg\varphi[o]$ ak $\mathcal{I} \models_{\Psi} \varphi[o]$
2. $\mathcal{I} \models_{\top} \varphi[o] \wedge \phi[o]$ ak $\mathcal{I} \models_{\top} \varphi[o]$ a zároveň $\mathcal{I} \models_{\top} \phi[o]$
 $\mathcal{I} \models_{\perp} \varphi[o] \wedge \phi[o]$ ak $\mathcal{I} \models_{\perp} \varphi[o]$ alebo $\mathcal{I} \models_{\perp} \phi[o]$
 $\mathcal{I} \models_{\Psi} \varphi[o] \wedge \phi[o]$ v ostatných prípadoch
3. $\mathcal{I} \models_{\top} (\varphi \Rightarrow \phi)[o]$ ak platí
 - (a) $\mathcal{I} \models_{\top} \varphi[o]$ a zároveň $\mathcal{I} \models_{\top} \phi[o]$
 - (b) $\mathcal{I} \models_{\Psi} \varphi[o]$ a zároveň $\mathcal{I} \models_{\top} \phi[o]$
 - (c) $\mathcal{I} \models_{\Psi} \varphi[o]$ a zároveň $\mathcal{I} \models_{\Psi} \phi[o]$
 - (d) $\mathcal{I} \models_{\perp} \varphi[o]$ $\mathcal{I} \models_{\perp} (\varphi \Rightarrow \phi)[o]$ ak $\mathcal{I} \models_{\top} \varphi[o]$ a zároveň $\mathcal{I} \models_{\perp} \phi[o]$
 $\mathcal{I} \models_{\Psi} (\varphi \Rightarrow \phi)[o]$ ak $\mathcal{I} \models_{\Psi} \varphi[o]$ a zároveň $\mathcal{I} \models_{\perp} \phi[o]$
4. Pre kvantifikovanú implikáciu $\forall X\iota$ platí:

$\mathcal{I} \models_{\top} \forall X\iota$ ak pre ľubovoľnú konštantu c platí $\mathcal{I} \models_{\top} \iota[X|c]$
 $\mathcal{I} \models_{\perp} \forall X\iota$ ak pre niektorú konštantu c platí $\mathcal{I} \models_{\perp} \iota[X|c]$
 inak $\mathcal{I} \models_{\Psi} \forall X\iota$

Definícia 1.1.10. Ak n -árny predikát p_r je prislúchajúci n -árnej relácii $r \subseteq D_1 \times D_2 \times \dots \times D_n$, potom v každej interpretácii $\mathcal{I}$ jazyka, ktorá obsahuje p_r , platí $\mathcal{I} \models_{\top} p_r(c_1, c_2, \dots, c_n)$ ak $(c_1, c_2, \dots, c_n) \in r$, inak $\mathcal{I} \models_{\perp} p_r(c_1, c_2, \dots, c_n)$.

Definícia 1.1.11. Interpretáciu $\mathcal{I}$ teórie $K_1 \wedge \dots \wedge K_n$ nazývame **model**, ak pre všetky $i \in \{1, \dots, n\}$ platí $\mathcal{I} \models_{\top} K_i$.

Definícia 1.1.12. Majme teóriu $K_1 \wedge \dots \wedge K_n$ a atomickú formulu Q . Potom teóriu $K_1 \wedge \dots \wedge K_n \wedge Q$ nazývame **teória s dotazom** Q alebo aj **program** resp. **Datalogový program**.

Definícia 1.1.13. Majme teóriu s dotazom $K_1 \wedge \dots \wedge K_n \wedge Q$, kde $X_1, \dots, X_k$ sú premenné v dotaze Q . **Výsledkom dotazu** (vzhľadom na model $\mathcal{I}$ teórie $K_1 \wedge \dots \wedge K_n$) nazývame množinu usporiadaných k -tic

$$\{(c_1, c_2, \dots, c_k) \mid \mathcal{I} \models_{\top} Q[X_1|c_1, X_2|c_2, \dots, X_k|c_k]\}.$$

Ak dotaz Q neobsahuje žiadnu premennú a platí $\mathcal{I} \models_{\top} Q$, výsledkom dotazu je $\top$, inak je výsledkom $\perp$.

Poznámka 1.1.2. Môžeme si všimnúť, že dotazom sa vieme pýtať iba otázky typu *platí* $p(K_1, \dots, K_n)$?, kde $K_1, \dots, K_n$ sú konštanty. Nevieme sa pýtať na opak (otázky typu *neplatí*...?).

Týmto dokážeme odpovedať na niektoré dotazy pre teórie, ktoré nemajú dvojhodnotový model. Ako príklad môžeme zobrať teóriu

$$\mathcal{T} = (\neg p \Rightarrow q) \wedge (\neg q \Rightarrow p).$$

Jediná validná interpretácia $\mathcal{I}_V$ je $\mathcal{I}_V \models_{\top} p$ a $\mathcal{I}_V \models_{\top} q$ (ak by sme zobrali ľubovoľnú inú interpretáciu $\mathcal{I}$, došli by sme k sporu $\mathcal{I} \models_{\top} p \wedge \mathcal{I} \not\models_{\top} p$ resp. $\mathcal{I} \models_{\perp} p \wedge \mathcal{I} \not\models_{\perp} p$). Ak by sme sa vedeli pýtať na záporné dotazy, dostali by sme pre teórie s dotazom $\mathcal{T} \wedge p$ a $\mathcal{T} \wedge \neg p$ výsledok dotazu $\perp$. S našim prístupom dostaneme, že výsledkom dotazu „*platí* p ?“ je *false* ($\perp$).

Definícia 1.1.14. Klauzulu

$$\forall X_1 \forall X_2 \dots \forall X_n (A_1 \wedge A_2 \wedge \dots \wedge A_i \wedge \neg A_{i+1} \wedge \neg A_{i+2} \wedge \dots \wedge \neg A_m) \Rightarrow B$$

nazývame **bezpečnou**, ak sa každá z premenných $X_1, X_2, \dots, X_n$ vyskytuje v niektorej z pozitívnych atomických formúl $A_1, A_2, \dots, A_i$. Teóriu, ktorá pozostáva iba z bezpečných klauzúl (spojených konjunkciou), nazývame **bezpečnou teóriou**.

Poznámka 1.1.3. Vo zvyšku práce budeme pracovať iba s bezpečnými klauzulami a bezpečnými teóriami. Dôvodom je, že potom nemusíme vôbec uvažovať o doménach predikátov. Každá bezpečná formula je totiž doménovo nezávislá.

Zoberme si nebezpečnú (a doménovo závislú) teóriu s dotazom

$$\mathcal{T} = (\forall X \neg p(X) \Rightarrow q(X)) \wedge q(X)$$

s interpretáciou $\mathcal{I}$ takou, že $\forall i \in \mathbb{N} : \mathcal{I} \models_{\top} q(i)$ a pre všetky ostatné konštanty c platí $\mathcal{I} \models_{\perp} q(c)$. Čo je potom ale výsledok dotazu $\mathcal{T}$? Intuitívne by to malo byť všetko, čo nie je prirodzené číslo. Čo to ale je? Ak je doménou predikátu p napríklad množina celých čísel $\mathbb{Z}$, potom výsledkom dotazu bude množina $\mathbb{Z} - \mathbb{N}$ (t.j. množina všetkých záporných čísel). Ak by doménou bola množina racionálnych čísel $\mathbb{Q}$, výsledkom dotazu bude $\mathbb{Q} - \mathbb{N}$. Pri doménovo závislých formulách domény predikátov ovplyvňujú výsledky dotazov.

Príkladom bezpečnej teórie s dotazom je napríklad

$$\mathcal{T}' = (\forall X r(X) \wedge \neg p(X) \Rightarrow q(X)) \wedge p(X)$$

s interpretáciou $\mathcal{I}'$ takou, že $\forall i \in \mathbb{N} : \mathcal{I}' \models_{\top} p(i)$ a $\forall c \in \mathbb{R} : \mathcal{I}' \models_{\top} r(c)$. V tejto teórii sme obmedzili množinu konštánt, ktoré má zmysel dopĺňať do predikátu p . Výsledok tohto dotazu je $\mathbb{R} - \mathbb{N}$, nezávisle od domén predikátov.

1.2 Rozšírenie Datalogu o funkčné symboly

Doteraz sme dosádzali do predikátov iba konštanty a premenné. Rozšírime jazyk logiky o tzv. funkčné symboly. Funkčný symbol f (s aritou n) reprezentuje ľubovoľnú funkciu $f : D_1 \times D_2 \times \dots \times D_n \rightarrow D$.

Funkčné symboly chceme zaviesť preto, že samotné konštanty a premenné nestačia na reprezentáciu zložitejších štruktúr. Príkladom zložitejšej štruktúry je zoznam. Zoznam vieme reprezentovať pomocou funkčných symbolov `nil` a `list`: `nil`, ktorý reprezentuje prázdny zoznam, a `list`, ktorého prvým argumentom je prvý prvok zoznamu, a druhým argumentom je zvyšok zoznamu. Zoznam obsahujúci prvky a, b a c (v tomto poradí) potom bude reprezentovať termom `list(a, list(b, list(c, nil)))`.

Definícia 1.2.1. Za **term** považujeme:

- ľubovoľný 0-árny funkčný symbol (ktorý považujeme za *konštantu*, môžeme zapisovať aj bez zátvoriek),
- ľubovoľnú premennú (budeme značiť veľkými písmenami latinskej abecedy),
- ak f je n -árny funkčný symbol a $t_1, t_2, \dots, t_n$ sú termy, potom $f(t_1, t_2, \dots, t_n)$ je term.

Dôležité je, že term pozostáva z konečného množstva symbolov.

Rozšírime definíciu jazyka logiky (1.1.2) o symboly označujúce funkčné symboly. Do predikátov (1.1.3 1.) potom nedosadzujeme premenné a konštanty, ale termy.

Definícia 1.2.2. **Ground term** je ľubovoľný term, v ktorom sa nevyskytujú premenné.

V definícii pre ohodnotenie premenných (1.1.7) sa daná funkcia predefinuje na funkciu, ktorá priradí každej premennej nie konštantu, ale *ground term*. Taktiež v definícii interpretácie jazyka (1.1.9) prepíšeme 4. časť na:

Pre kvantifikovanú implikáciu $\forall X\iota$ platí:

$\mathcal{I} \models_{\top} \forall X\iota$ ak pre *ľubovoľný ground term* c platí $\mathcal{I} \models_{\top} \iota[X|c]$,

$\mathcal{I} \models_{\perp} \forall X\iota$ ak pre *niektorý ground term* c platí $\mathcal{I} \models_{\perp} \iota[X|c]$,

inak $\mathcal{I} \models_{\bot} \forall X\iota$.

Ostatné definície môžu ostať tak, ako boli popísané v predošlej kapitole.

1.3 Vstavané predikáty

Klasický Datalog povoľuje prácu iba s predikátmi definovanými v programe, či už pomocou faktov alebo pravidiel. V prípade, že chceme pracovať s veľkou databázou s niekoľkými tabuľkami, museli by sme pre každú tabuľku vytvoriť predikát a naplniť ho faktami v každom dotaze. To by bolo veľmi neefektívne a nepraktické. Preto zavedieme tzv. **vstavané predikáty**. Tie budú práve reprezentovať veľké tabuľky alebo predikáty, ktoré by bolo nepraktické definovať a implementovať v Datalogu. Implementované budú v imperatívnom programovacom jazyku, v našom prípade v Jave, čiže môžu pracovať aj so zložitejšími vstupmi, napríklad s inými predikátmi, termami a zoznamami. Vieme ich použiť v pravidlách rovnako ako bežné predikáty, s jedným obmedzením. Nemôžeme ich predefinovať ani dodefinovať, čiže sa nemôžu vyskytovať v dôsledku implikácie. Vstavané predikáty budeme označovať pomocou \$ pred menom predikátu.

Definícia 1.3.1. Pod pojmom **parameter** rozumieme:

1. ľubovoľný term
2. ľubovoľný predikát alebo vstavaný predikát
3. ľubovoľný zoznam parametrov, ktorý zapisujeme ako $[P_1, P_2, \dots, P_n]$, kde $P_1, P_2, \dots, P_n$ sú parametre

Definícia 1.3.2. Atomické formuly sú

1. $p(t_1, t_2, \dots, t_n)$, kde p je n -árny predikát a $t_1, t_2, \dots, t_n$ sú termy
2. $\$p(P_1, P_2, \dots, P_n)$, kde $\$p$ je n -árny vstavaný predikát a $P_1, P_2, \dots, P_n$ sú parametre

1.4 Syntax rozšíreného Datalogu

Zoberme si formálny zápis relatívne jednoduchej teórie s dotazom:

$$\begin{aligned} & [\forall X, Y (\text{parent}(X, Y) \Rightarrow \text{ancestor}(X, Y))] \wedge \\ & [\forall X, Y, Z ((\text{parent}(X, Z) \wedge \text{ancestor}(Z, Y)) \Rightarrow \text{ancestor}(X, Y))] \wedge \\ & \text{ancestor}(X, Y) \end{aligned}$$

Príklad 1.1

Tento zápis sa rýchlo stáva neprehľadným a dlhým. Preto Datalog používa skrátенý zápis.

Klauzula

$$\forall X_1, \dots, X_k ((P_1 \wedge \dots \wedge P_i \wedge \neg P_{i+1} \wedge \dots \wedge \neg P_n) \Rightarrow Q),$$

kde $X_1, \dots, X_k$ sú všetky premenné vyskytujúce sa v termoch použitých v predikátoch $P_1, \dots, P_n$ a Q , sa v skrátенom zápise zapisuje ako

$$Q \leftarrow P_1, \dots, P_i, \neg P_{i+1}, \dots, \neg P_n.$$

Teórii s dotazom $K_1 \wedge K_2 \wedge \dots \wedge K_n \wedge Q$ zodpovedá $D_1 D_2 \dots D_n ?Q$, kde D_i je skrátенý zápis klauzuly K_i .

Skôr spomenutá teória je reprezentovaná skrátенým zápisom:

$$\begin{aligned} & \text{ancestor}(X, Y) \leftarrow \text{parent}(X, Y). \\ & \text{ancestor}(X, Y) \leftarrow \text{parent}(X, Z), \text{ancestor}(Z, Y). \\ & ? \text{ancestor}(X, Y) \end{aligned}$$

Príklad 1.2

Poznámka 1.4.1. So znakom **t**, resp. **f** budeme označovať 0-árny predikát, pre ktorý pre každú interpretáciu $\mathcal{I}$ platí $\mathcal{I} \models_{\top} \mathbf{t}$, resp. $\mathcal{I} \models_{\perp} \mathbf{f}$.

Definícia 1.4.1. Klauzulu typu $p(t_1, \dots, t_n) \leftarrow \mathbf{t}$, kde p je n -árny predikát a $t_1, \dots, t_n$ sú termy, nazývame **fakt** alebo **definícia**. Klasicky ich skrátene zapisujeme ako $p(t_1, \dots, t_n)$. (bodka na konci je súčasťou skrátенého zápisu). Keďže ale často potrebujeme vyjadriť pre jeden predikát viacero faktov, zvolíme nasledujúci zápis. Fakty

$$\begin{aligned} & p(t_{1,1}, \dots, t_{1,n}). \\ & \vdots \\ & p(t_{k,1}, \dots, t_{k,n}). \end{aligned}$$

zapišeme ako

$$p \leftarrow \{(t_{1,1}, \dots, t_{1,n}), \dots, (t_{k,1}, \dots, t_{k,n})\}.$$

(zdôrazňujem, že bodka na konci je súčasťou zápisu).

V ASCII zápise Datalogových programov a dotazov sa používajú alternatívne znaky, konkrétne:

- $\leftarrow \rightsquigarrow :-$
- $\neg \rightsquigarrow \setminus +$
- Na označenie dotazov sa namiesto $?$ používa $?-$.

Doteraz spomínaná teória (rozšírená o fakty) by potom bola zapísaná ako:

```
ancestor :- {(jozo, fero), (fero, sano)}.
ancestor(X, Y) :- parent(X, Y).
ancestor(X, Y) :- parent(X, Z), ancestor(Z, Y).
?- ancestor(X, Y).
```

Príklad 1.3

1.5 Sémantika Datalogu

Zoberme si veľmi jednoduchú teóriu:

$$p = \{(1)\}.$$

Pre túto teóriu existuje niekoľko modelov (dokonca ich je nekonečne veľa). Najjednoduchší z nich je $\mathcal{I} \models_{\top} p(1)$ a pre všetky ostatné formuly je interpretácia nepravdivá. Ďalšími modelmi môžu byť napríklad:

- $\mathcal{I}' \models_{\top} p(i), \forall i \in \mathbb{N}$ a pre všetky ostatné formuly je interpretácia nepravdivá,
- $\mathcal{I}'' \models_{\top} p(i), \forall i \in \mathbb{R}$ a pre všetky ostatné formuly je interpretácia nepravdivá,
- $\mathcal{I}''' \models_{\top} p(1), \mathcal{I}''' \models_{\top} p(\text{Pes}), \mathcal{I}''' \models_{\top} p(47), \mathcal{I}''' \models_{\top} p(\text{Štvorec})$ a pre všetky ostatné formuly je interpretácia nepravdivá.

Ako sémantiku našich Datalogových programov budeme uvažovať *well-founded model*. Well-founded model je minimálny stabilný trojhodnotový model.

Trojhodnotový model znamená, že interpretácia priraduje atomickým formulám hodnoty *true* $\top$, *false* $\perp$ a *unknown* $\uplus$.

Minimálny model znamená, že spomedzi všetkých modelov vyberáme ten, ktorý obsahuje najmenej pravdivých atómov. Inými slovami, chceme odvodiť len tie fakty, ktoré sú naozaj nutné. Ak existuje viacero takých modelov, vyberieme si ten s najmenším počtom pravdivých atómov.

Príklad: Pre teóriu

$$p = \{(1)\}.$$

máme viacero modelov. Interpretácia, kde platí iba $p(1)$, je modelom. Interpretácia, kde platí $p(1)$, $p(2)$ a $p(3)$, je tiež modelom. Minimálny model je však ten prvý, pretože obsahuje najmenej pravdivých atómov.

Stabilný model je taký model, ktorý sa nezmení po aplikácii *Gelfond-Lifschitz Transformation* (GLT). GLT funguje takto:

1. Vezmeme aktuálnu interpretáciu.
2. Z programu odstránime všetky pravidlá, ktorých negované podmienky sú v tejto interpretácii pravdivé.
3. Zo zostávajúcich pravidiel odstránime všetky negácie.
4. Pre takto upravený program (bez negácií) nájdeme minimálny model.
5. Ak sa tento minimálny model rovná našej pôvodnej interpretácii, potom je naša interpretácia stabilný model.

Zoberme si program

- a.
- b :- \+ c.
- c :- \+ b.
- d :- a, \+ c.

a kandidátnu interpretáciu $\mathcal{I}$, pre ktorú platí

$$\mathcal{I} \models_{\top} a, \mathcal{I} \models_{\top} b, \mathcal{I} \models_{\perp} c, \mathcal{I} \models_{\top} d.$$

Pri aplikácii GLT najprv odstránime tie pravidlá, ktorých negované podmienky sú podľa $\mathcal{I}$ pravdivé. Pravidlo $c :- \backslash+ b.$ sa preto odstráni, keďže b je v interpretácii $\mathcal{I}$ pravdivé. V ostatných pravidlách potom odstránime negácie, a dostaneme program

- a.
- b.
- d :- a.

Minimálny model takto upraveného programu obsahuje práve atómy **a**, **b** a **d**. Keďže sa zhoduje s interpretáciou, z ktorej sme vychádzali, daná interpretácia je stabilný model pôvodného programu.

Well-founded model môžeme chápať ako niečo, čo je spoločné pre všetky stabilné modely. Funguje nasledovne:

- Atómy, ktoré sú $\top$ vo **všetkých** stabilných modeloch, označíme ako $\top$,
- Atómy, ktoré sú $\perp$ vo **všetkých** stabilných modeloch, označíme ako $\perp$,
- Atómy, ktoré sa v rôznych stabilných modeloch líšia, ponecháme ako $\mathbb{U}$.

V nasledujúcom príklade ukážeme, ako nájsť well-founded model pomocou iteratívneho procesu. Podľa [5] a [10] sa postup označuje aj ako iteratívny vzostup.

Algoritmus nájdenia well-founded modelu:

1. Začneme interpretáciou, kde sú všetky atómy $\perp$.
2. Opakovane aplikujeme GLT transformáciu.
3. Po každej transformácii nájdeme minimálny model upraveného programu.
4. Tento minimálny model použijeme ako novú interpretáciu pre ďalšiu iteráciu.
5. Keď sa interpretácia prestane meniť alebo dostaneme niektorú interpretáciu druhýkrát, iterácia skončila.
6. Výsledný well-founded model získame z hodnôt, ktoré sa stabilizujú, respektíve oscilujú.

Príklad nájdenia well-founded modelu pre program:

```

a.
b :- a.
p :- \+ q.
q :- \+ p.
u :- v.

```

Ako prvú interpretáciu zvolíme $\mathcal{I}_0$, kde všetky atómy sú nastavené na $\perp$. Po aplikácii GLT dostaneme program

$a.$
 $b :- a.$
 $p.$
 $q.$
 $u :- v.$

Minimálny model tohto programu je $\mathcal{I}_1$, kde a , b , p a q sú $\top$, a u a v sú $\perp$.

Po druhej aplikácii GLT dostaneme program

$a.$
 $b :- a.$
 $u :- v.$

Minimálny model tohto programu je $\mathcal{I}_2$, kde a a b sú $\top$, a p , q , u a v sú $\perp$.

Po tretej aplikácii GLT a následnom nájdení minimálneho modelu dostaneme $\mathcal{I}_3$, ktorá sa zhoduje s $\mathcal{I}_1$, čiže iterácia sa zastavila. Vo výslednom well-founded modeli $\mathcal{I}$ budú stabilizované atómy a a b nastavené na $\top$, atómy u a v nastavené na $\perp$, a atómy p a q zostanú $\perp$, keďže oscilujú medzi $\top$ a $\perp$. Celý proces je zhrnutý v nasledujúcej tabuľke:

Atóm	$\mathcal{I}_0$	$\mathcal{I}_1$	$\mathcal{I}_2$	$\mathcal{I}_3$	$\mathcal{I}$
a	$\perp$	$\top$	$\top$	$\top$	$\top$
b	$\perp$	$\top$	$\top$	$\top$	$\top$
u	$\perp$	$\perp$	$\perp$	$\perp$	$\perp$
v	$\perp$	$\perp$	$\perp$	$\perp$	$\perp$
p	$\perp$	$\top$	$\perp$	$\top$	$\perp$
q	$\perp$	$\top$	$\perp$	$\top$	$\perp$

Kapitola 2

Relačná algebra

V tejto časti sa inšpirujeme relačnou algebrou z [2] a klasickou *učebnicovou* relačnou algebrou a definujeme našu vlastnú.

2.1 Učebnicová relačná algebra

Klasická relačná algebra pracuje s reláciami, ktoré majú väčšinou jednotlivé atribúty pomenované. Potom ich vieme jednoducho reprezentovať pomocou tabuliek.

$R \in \text{Meno} \times \text{Výška}$ $R = \{(\text{Adam}, 175), (\text{Boris}, 183), (\text{Cecil}, 192)\}$	R	
	Meno	Výška
	Adam	175
	Boris	183
	Cecil	192

Príklad 2.1

Na manipuláciu s týmito reláciami existuje niekoľko operátorov:

Množinové operátory

zjednotenie množín $\cup$, rozdiel množín $-$, (prienik množín $\cap$, ale ten sa dá vyjadriť aj za pomoci rozdielu $A \cap B = A - (A - B)$)

Pre relácie, na ktoré aplikujeme tieto operátory musí platiť, že majú identické domény atribútov. Predtým, ako aplikujeme operátor na dve relácie, musíme usporiadať ich atribúty v jednotlivých záznamoch do rovnakého poradia.

Karteziánsky súčin $\times$

$R \times S$, kde R a S sú relácie. Výsledná relácia sa dá matematicky zapísať nasledovne:

$$R \times S = \{(a_1, \dots, a_n, b_1, \dots, b_m) \mid (a_1, \dots, a_n) \in R, (b_1, \dots, b_m) \in S\}$$

		$R \times S$			
		X	R.Y	S.Y	Z
R					
X	Y	S			
		Y	Z		
A	a	1	10	A	a
B	b	2	20	B	b
C	c	3	30	C	c
				A	a
				B	b
				C	c
				A	a
				B	b
				C	c

Príklad 2.2

Projekcia Π

$\Pi_{a_1, \dots, a_n}(R)$, kde $a_1, \dots, a_n$ sú názvy atribútov relácie R , vráti novú reláciu, ktorá obsahuje „iba stĺpce“ $a_1, \dots, a_n$. Výsledok je stále relácia (čiže aj množina), takže neobsahuje duplicitné záznamy.

R			$\Pi_{\text{Meno}, \text{Zviera}}(R)$		$\Pi_{\text{Mesto}}(R)$
Meno	Mesto	Zviera	Meno	Zviera	Mesto
Adam	Bratislava	Pes	Adam	Pes	Bratislava Košice Lučenec Poprad
Boris	Bratislava	Mačka	Boris	Mačka	
Cecil	Košice	Pes	Cecil	Pes	
Dano	Lučenec	Zajac	Dano	Zajac	
Erik	Poprad	Kôň	Erik	Kôň	
Fero	Košice	Mačka	Fero	Mačka	

Príklad 2.3

Selekcia σ

$\sigma_C(R)$, kde C je podmienka, ktorá obsahuje atribúty relácie R . Výsledná relácia je podmnožina relácie R obsahujúca iba tie záznamy, ktoré spĺňajú podmienku C .

R					
Meno	Mesto	Zviera	$\sigma_{\text{Mesto}=\text{Bratislava} \vee \text{Zviera}=\text{Mačka}}(R)$		
Adam	Bratislava	Pes	Meno	Mesto	Zviera
Boris	Bratislava	Mačka	Adam	Bratislava	Pes
Cecil	Košice	Pes	Boris	Bratislava	Mačka
Dano	Lučenec	Zajac	Fero	Košice	Mačka
Erik	Poprad	Kôň			
Fero	Košice	Mačka			

Príklad 2.4

Prirodzený (natural) join $\bowtie$

$R \bowtie S$, kde R a S sú relácie. Podobne ako v karteziánskom súčine párujeme záznamy z dvoch relácií, ale iba tie záznamy z R a S , ktoré sa zhodujú na atribútoch spoločných pre R a S . V množinovom zápise:

$$\begin{aligned}
 R &= A_1 \times \cdots \times A_n \times C_1 \times \cdots \times C_k \\
 S &= B_1 \times \cdots \times B_n \times C_1 \times \cdots \times C_k \\
 R \times S &= \{(a_1, \dots, a_n, c_1, \dots, c_k, b_1, \dots, b_m) \mid \\
 &\quad (a_1, \dots, a_n, c_1, \dots, c_k) \in R, \\
 &\quad (b_1, \dots, b_m, c'_1, \dots, c'_k) \in S, \\
 &\quad c_1 = c'_1, \dots, c_k = c'_k\}
 \end{aligned}$$

R				$R \bowtie S$		
Meno	Mesto	S		Meno	Mesto	Rozloha
Adam	Bratislava	Mesto	Rozloha	Adam	Bratislava	368
Boris	Bratislava	Bratislava	368	Boris	Bratislava	368
Cecil	Košice	Košice	242	Cecil	Košice	242
Dano	Lučenec	Lučenec	47	Dano	Lučenec	47
Erik	Poprad	Poprad	63	Erik	Poprad	63
Fero	Košice			Fero	Košice	242

Príklad 2.5

Antijoin $\triangleright$

$R \triangleright S$, kde R a S sú relácie. Vo výslednej relácii sú tie záznamy z R , pre ktoré neexistuje záznam v S , s ktorým by sa zhodovali na spoločných atribútoch. V množinovom zápise:

$$R = A_1 \times \cdots \times A_n \times C_1 \times \cdots \times C_k$$

$$S = B_1 \times \cdots \times B_n \times C_1 \times \cdots \times C_k$$

$$R \times S = \{(a_1, \dots, a_n, c_1, \dots, c_k) \in R \mid \forall (b_1, \dots, b_n, c'_1, \dots, c'_k) \in S, \exists i : c_i \neq c'_i\}$$

Z			
Meno	Mesto		
Adam	Bratislava	V	$Z \triangleright V$
Boris	Bratislava		
Cecil	Košice	Bratislava	Cecil
Dano	Lučenec	Lučenec	Erik
Erik	Poprad		Fero
Fero	Košice		

Príklad 2.6

Theta-join $\bowtie_C$

$R \bowtie_C S$, kde R a S sú relácie a C je podmienka, v ktorej sa vyskytujú atribúty z R a S . Natural join nám povolil spojiť dva záznamy iba ak ich spoločné atribúty boli rovnaké. Theta-join popáruje každú dvojicu záznamov z R a S , ktoré spĺňajú podmienku C .

M		R			$M \bowtie_{R.Od < M.Roz \wedge M.Roz < R.Do} R$				
Mesto	Roz	Od	Do	Veľ	Mesto	Roz	Od	Do	Veľ
Bratislava	368	0	100	Malé	Bratislava	368	301	1000	Veľké
Košice	242	101	300	Stredné	Košice	242	101	300	Stredné
Lučenec	47	301	1000	Veľké	Lučenec	47	0	100	Malé
Poprad	63				Poprad	63	0	100	Malé

Príklad 2.7

Premenovanie ρ

$\rho_{A/B}(R)$, kde R je relácia, A je názov atribútu z relácie R a B je nový názov atribútu. Výsledkom bude relácia s rovnakými záznamami, iba atribút A sa premenuje na B .

R			$\rho_{\text{Mesto/Obec}}(R)$		
Meno	Mesto	Zviera	Meno	Obec	Zviera
Adam	Bratislava	Pes	Adam	Bratislava	Pes
Boris	Bratislava	Mačka	Boris	Bratislava	Mačka
Cecil	Košice	Pes	Cecil	Košice	Pes
Dano	Lučenec	Zajac	Dano	Lučenec	Zajac
Erik	Poprad	Kôň	Erik	Poprad	Kôň
Fero	Košice	Mačka	Fero	Košice	Mačka

Príklad 2.8

Iné join-y

V niektorých knihách sa spomínajú aj iné variácie join-ov ako *left outer join*, *right outer join* alebo *full outer join*. My sa s nimi nebudeme zaoberať, keďže sa dajú vyskladať z predchádzajúcich operátorov. Pre ich správne fungovanie treba ale zaviesť špeciálnu konštantu, ktorá sa v literatúre označuje ako ω , ε , **null** alebo **none**.

2.2 Naša relačná algebra

Pre jednoduchší preklad Datalogu do relačnej algebry sme si zvolili nasledujúcu algebru so štyrmi operátormi (inšpirovaná algebrou z [2]). Tiež pracuje s reláciami, ale nepotrebuje vopred pomenované atribúty. Vždy, keď potrebuje pracovať s „názvami stĺpcov“, sú explicitne vymenované.

UNION ($[R_1, \dots, R_n]$), kde $R_1, \dots, R_n$ sú relácie s rovnakým počtom atribútov. Výsledná relácia bude obsahovať všetky záznamy z každej relácie R_1 až R_n (až na duplikáty). Formálne $\text{UNION}([R_1, \dots, R_n]) = \bigcup_{i=1}^n R_i$.

			UNION([A, B, C])	
			11	a
			12	b
			13	c
A	B	C	21	a
11	a	21	a	a
12	b	22	b	b
13	c	23	c	c
			31	a
			32	b
			33	c

Príklad 2.9

JOIN([$R_1, \dots, R_n$], [[$T_{1,1}, \dots, T_{1,a_1}$], ..., [$T_{n,1}, T_{n,a_n}$]], [$T_1, \dots, T_k$]), kde R_i je relácia s aritou a_i , $T_{i,j}$ sú vstupné termy a T_l sú výstupné termy.

Výsledná relácia bude nasledujúca. Nech $P_1, \dots, P_p$ sú všetky premenné vyskytujúce sa v termoch $T_{1,1}, \dots, T_{1,a_1}, T_{2,1}, \dots, T_{n,a_n}$. Nech množina M obsahuje všetky $(c_1, \dots, c_p)$ také, pre ktoré platí

$$(T_{i,1}[P_1|c_1, \dots, P_p|c_p], \dots, T_{i,a_i}[P_1|c_1, \dots, P_p|c_p]) \in R_i, \forall i \in \{1, \dots, n\}.$$

Potom vo výslednej relácii R budú záznamy

$$R = \{(T_1[P_1|k_1, \dots, P_p|k_p], \dots, T_k[P_1|k_1, \dots, P_p|k_p]) \mid (k_1, \dots, k_p) \in M\}.$$

G		JOIN([G, G], [[X, Z], [Z, Y]], [X, Y])	
1	2	1	3
2	3	2	4
3	4	2	5
3	5		

Príklad 2.10

ANTIJOIN([$R_1, \dots, R_n$], [[$T_{1,1}, \dots, T_{1,a_1}$], ..., [$T_{n,1}, T_{n,a_n}$]], [$T_1, \dots, T_k$]), kde R_i je relácia s aritou a_i , $T_{i,j}$ sú vstupné termy a T_l sú výstupné termy.

Výsledná relácia bude nasledujúca. Nech $P_1, \dots, P_p$ sú všetky premenné vyskytujúce sa v termoch $T_{1,1}, \dots, T_{1,a_1}, T_{2,1}, \dots, T_{n,a_n}$. Nech množina M obsahuje všetky $(c_1, \dots, c_p)$ také, pre ktoré platí

$$(T_{1,1}[P_1|c_1, \dots, P_p|c_p], \dots, T_{1,a_1}[P_1|c_1, \dots, P_p|c_p]) \in R_1$$

a zároveň pre žiadne $i \in \{2, \dots, n\}$ neplatí

$$(T_{i,1}[P_1|c_1, \dots, P_p|c_p], \dots, T_{i,a_i}[P_1|c_1, \dots, P_p|c_p]) \in R_i.$$

Potom vo výslednej relácii R budú záznamy

$$R = \{(T_1[P_1|k_1, \dots, P_p|k_p], \dots, T_k[P_1|k_1, \dots, P_p|k_p]) \mid (k_1, \dots, k_p) \in M\}.$$

Nech f je funkčný symbol, ktorý pre ľubovoľný reťazec vráti jeho prvý znak.

U		$\mathbf{ANTIJOIN}([U, P], [[M, B], [f(B)]], [M])$	
Adam	Bratislava	P	Adam
Boris	Bratislava		Dano
Cecil	Košice		Erik
Dano	Lučenec		Fero
Erik	Poprad		
Fero	Košice		

Príklad 2.11

$\mathbf{REC}(N, R)$, kde N je názov relácie a R je relácia. Tento operátor definuje reláciu s názvom N a dovoľuje použiť v relácii R odkaz na ňu.

$$\mathbf{REC}(t, \mathbf{UNION}([\$s, \mathbf{JOIN}([t, t], [[X, Z], [Z, Y]], [X, Y]])))$$

Relácia t je tranzitívny uzáver vstavanej relácie s .

Príklad 2.12

2.2.1 Vstavané operátory

Ako sme si ukázali skôr (definícia 1.1.10), na predikáty a relácie sa vieme pozeráť ako na rovnaké objekty. Taktiež na operátory **JOIN**, **ANTIJOIN**, **UNION** a **REC** sa vieme pozeráť ako na relácie, keďže ich výstupom je vždy relácia. Preto ku každému vstavanému predikátu vieme definovať vstavaný operátor, ktorý bude fungovať rovnako a bude mať rovnaké vstupy. Jediný rozdiel bude formálny, keďže vstavané operátory budú mať výstupom reláciu, zatiaľ čo vstavané predikáty majú výstupom pravdivostnú hodnotu. Takýto prístup si ale vyžadoval zmenu parsera relačnej algebry [2].

Definícia 2.2.1. Parameter (*v kontexte relačnej algebry*) je:

1. ľubovoľný term
2. ľubovoľnú *reláciu* alebo vstavaný operátor (ktorého výstupom je relácia)
3. ľubovoľný zoznam parametrov, ktorý zapisujeme ako $[P_1, P_2, \dots, P_n]$,
kde $P_1, P_2, \dots, P_n$ sú parametre

Definícia 2.2.2. Operátor je $\$O(P_1, P_2, \dots, P_n)$, kde $\$O$ je názov operátora a $P_1, P_2, \dots, P_n$ sú parametre operátora. Výstupom operátora je relácia.

Operátory **JOIN**, **ANTIJOIN**, **UNION** a **REC** budeme v ďalšom texte niekedy zapisovať bez znaku \$, aj keď sú v relačnej algebre definované ako vstavané operátory. Od kompilátora relačnej algebry vyžadujeme, aby boli tieto štyri vstavané operátory k dispozícii.

2.3 Inklúzia medzi učebnicovou a našou relačnou algebrou

V nasledujúcej kapitole sa pokúsime ukázať, že naša relačná algebra má aspoň takú výpočtovú silu ako učebnicová relačná algebra. To znamená, že každý výraz v učebnicovej relačnej algebre môžeme vyjadriť pomocou výrazov v našej relačnej algebre. Dôkazy nebudú úplne formálne správne, ale mali by byť dostatočne jasné a zrozumiteľné, aby bolo zrejmé, ako by sa mal ľubovoľný program v učebnicovej relačnej algebre prepísať do našej algebry. Pre viac informácií o našej relačnej algebre odporúčame pozrieť [2] a [4].

Množinové operátory

Zjednotenie množín (relácií) $R \cup S$ vieme prepísať ako **UNION** ($[R, S]$). Rozdiel množín $R - S$ prepíšeme ako

$$\mathbf{ANTIJOIN}([R, S], [[A_1, A_2, \dots, A_n], [A_1, A_2, \dots, A_n]], [A_1, A_2, \dots, A_n]).$$

Keďže prienik vieme vyjadriť pomocou rozdielu, budeme ho vedieť zapísať pomocou **ANTIJOIN**.

Karteziánsky súčin $\times$

Karteziánsky súčin $R \times S$ vieme prepísať pomocou **JOIN**. Jednoducho vymenujeme všetky atribúty z R a S ako vstupné termy a výstupné termy.

$$R \times S \approx \mathbf{JOIN}([R, S], \\ [[A_1, A_2, \dots, A_n], [B_1, B_2, \dots, B_m]], \\ [A_1, A_2, \dots, A_n, B_1, B_2, \dots, B_m])$$

Projekcia Π

Projekcia je už zakomponovaná v **JOIN** a **ANTIJOIN**. Ak ale chceme vyjadriť iba projekciu, môžeme použiť **JOIN** s pomenovanými vstupnými termami a vymenovanými výstupnými termami, ktoré sú podmnožinou vstupných termov. Napríklad $\Pi_{A_1, A_3}(R)$ prepíšeme ako

$$\mathbf{JOIN}([R], [[A_1, A_2, A_3, \dots, A_n], [A_1, A_3]]).$$

Treba si ale dávať pozor, že v našej algebre záleží na poradí atribútov a v učebnicovej algebre záleží iba na ich názvoch. Preto je rozdiel medzi

$$\begin{aligned} &\mathbf{JOIN}([R], [[A_1, A_2, A_3], [A_1, A_3]]), \\ &\mathbf{JOIN}([R], [[A_1, A_3, A_2], [A_1, A_3]]) \text{ a} \\ &\mathbf{JOIN}([R], [[A_1, A_2, A_3], [A_3, A_1]]). \end{aligned}$$

Selekcia σ

Pre selekciu využijeme veľkú výpočtovú silu funkčných symbolov. Zoberme si selekciu $\sigma_C(R)$. Skonstruujeme funkčný symbol f_C tak, že $f_C(p_1, p_2, \dots, p_n) = \mathbf{t}$ práve vtedy, keď podmienka C platí pre záznam $(p_1, p_2, \dots, p_n)$. Pre všetky ostatné vstupy bude f_C vracieť $\mathbf{f}$. Potom môžeme selekciu $\sigma_C(R)$ prepísať ako

$$\mathbf{JOIN}([R, \$true], [[p_1, p_2, \dots, p_n], [f_C(p_1, p_2, \dots, p_n)]], [p_1, p_2, \dots, p_n, \mathbf{t}]).$$

Výsledná relácia má však o jeden atribút viac, preto ju treba ešte *obaliť* projekciou (joinom), ktorá nám tento atribút odstráni.

Prirodzený (natural) join $\bowtie$

Opäť si musíme dávať pozor na poradie atribútov. Preklad $R \bowtie S$ bude ale potom priamočiary. Ukážeme na príklade, keď relácie R a S majú spoločné atribúty $C_1, C_2, \dots, C_k$

na konci.

$$R \bowtie S \approx \mathbf{JOIN}([R, S], \\ [[A_1, \dots, A_n, C_1, \dots, C_k], [B_1, \dots, B_m, C_1, \dots, C_k]], \\ [A_1, \dots, A_n, C_1, \dots, C_k, B_1, \dots, B_m])$$

Antijoin $\triangleright$

Antijoin $R \triangleright S$ prepíšeme v podstate rovnako ako natural join. Znovu predpokladáme, že spoločné atribúty $C_1, C_2, \dots, C_k$ sú *na konci*.

$$R \triangleright S \approx \mathbf{ANTIJOIN}([R, S], \\ [[A_1, \dots, A_n, C_1, \dots, C_k], [B_1, \dots, B_m, C_1, \dots, C_k]], \\ [A_1, \dots, A_n, C_1, \dots, C_k])$$

Theta-join $\bowtie_C$

Ako pri selekcii, aj tu využijeme funkčné symboly. Zoberme si theta-join $R \bowtie_C S$. Skonstruujeme funkčný symbol f_C tak, že $f_C(p_1, p_2, \dots, p_n, q_1, q_2, \dots, q_m) = \mathbf{t}$ práve vtedy, keď podmienka C platí pre záznam $(p_1, p_2, \dots, p_n)$ z relácie R a záznam $(q_1, q_2, \dots, q_m)$ z relácie S . Pre všetky ostatné vstupy bude f_C vracaať $\mathbf{f}$. Potom dokážeme theta-join $R \bowtie_C S$ prepísať ako

$$\mathbf{JOIN}([R, S, \$true], \\ [[A_1, \dots, A_n], [B_1, \dots, B_m], [f_C(A_1, \dots, A_n, B_1, \dots, B_m)]], \\ [A_1, \dots, A_n, B_1, \dots, B_m, \mathbf{t}])$$

Výsledná relácia má však opäť o jeden atribút viac, preto ju opäť treba *obaliť* projekciou (joinom), pomocou ktorej tento atribút odstránime.

Premenovanie ρ

Keďže v **JOIN** a **ANTIJOIN** zakaždým explicitne vymenujeme všetky vstupné a výstupné termy, premenovanie ρ nepredstavuje žiaden problém.

Kapitola 3

Kompilátor

3.1 ANTLR

Náš kompilátor používa generátor *parserov* **AN**other **T**ool for **L**anguage **R**ecognition. V tejto časti si priblížime, ako funguje *ANTLR* a ako prebieha preklad z Datalogu do relačnej algebry.

3.1.1 Rýchlokurz formálnych jazykov

Definícia 3.1.1. Pod **abecedou** rozumieme ľubovoľnú *neprázdnu konečnú* množinu symbolov (znakov).

Definícia 3.1.2. **Slovo** je *konečná* postupnosť znakov (z nejakej abecedy Σ). Prázdne slovo sa označuje ε .

Definícia 3.1.3. **Jazyk** nad abecedou Σ je ľubovoľná množina slov nad Σ .

Definícia 3.1.4. **Zreťazením slov** $w_1 = a_1 \dots a_n$, $w_2 = b_1 \dots b_m$, $a_1, \dots, a_n, b_1, \dots, b_m \in \Sigma$ dostaneme slovo $w_1 \cdot w_2 = w_1 w_2 = a_1 \dots a_n b_1 \dots b_m$.

Definícia 3.1.5. **Mocnina slova** je definovaná ako $w^0 = \varepsilon$, $w^{n+1} = w^n w$, $\forall n \in \mathbb{N}$.

Poznámka 3.1.1. Abecedu Σ vieme chápať aj ako množinu všetkých jednoznakových slov nad Σ .

Definícia 3.1.6. **Zreťazenie jazykov** L_1 (nad abecedou Σ_1) a L_2 (nad abecedou Σ_2) je jazyk $L_1 \cdot L_2 = L_1 L_2 = \{w_1 w_2 \mid w_1 \in L_1, w_2 \in L_2\}$ nad abecedou $\Sigma_1 \cup \Sigma_2$.

Definícia 3.1.7. **Mocnina jazyka** L je definovaná ako $L^0 = \{\varepsilon\}$, $L^{n+1} = L^n L$, $\forall n \in \mathbb{N}$.

$$\begin{aligned} L^+ &= \bigcup_{n>0} L^n \\ L^* &= \bigcup_{n\geq 0} L^n \end{aligned}$$

Definícia 3.1.8. Regulárna gramatika je štvorica $G = (N, T, P, \sigma)$, kde N je abeceda neterminálov, T je abeceda terminálov, $P \subseteq_{kon} N \times (T^* \cup T^*N)$ je *konečná* množina prepisovacích pravidiel a $\sigma \in N$ je počiatkový neterminál. Prepisovacie pravidlá teda prepisujú jeden neterminál na ľubovoľné slovo z terminálov za ktorým môže, ale nemusí, nasledovať jeden neterminál.

Definícia 3.1.9. Bezkontextová gramatika je štvorica $G = (N, T, P, \sigma)$, kde N je abeceda neterminálov, T je abeceda terminálov, $P \subseteq_{kon} N \times (N \cup T)^*$ je *konečná* množina prepisovacích pravidiel a $\sigma \in N$ je počiatkový neterminál. Prepisovacie pravidlá teda prepisujú jeden neterminál na ľubovoľné slovo z terminálov a neterminálov.

Poznámka 3.1.2. Pravidlá z P budeme zapisovať v tvare $n \rightarrow w \in P$ namiesto $(n, w) \in P$. Pravidlá s rovnakou ľavou stranou $n \rightarrow w_1, n \rightarrow w_2, \dots, n \rightarrow w_i$ budeme zapisovať zjednodušene ako $n \rightarrow w_1 \mid w_2 \mid \dots \mid w_i$.

Definícia 3.1.10. Krok odvodenia v gramatike G je binárna relácia $\Rightarrow_G$ nad $(N \cup T)^*$. Slová x, y sú v relácii $\Rightarrow_G$ práve vtedy, keď $x = w_1nw_2, y = w_1sw_2$ a $n \rightarrow s$ je pravidlo v P .

Definícia 3.1.11. Jazyk generovaný gramatikou G je množina

$$L(G) = \{w \in T^* \mid \sigma \Rightarrow_G^* w\}.$$

Regulárne jazyky, resp. **bezkontextové jazyky** sú jazyky, ktoré sú generované *regulárnou*, resp. *bezkontextovou* gramatikou.

Definícia 3.1.12. Odvodenie slova w (v gramatike G) $\sigma \Rightarrow w_1 \Rightarrow w_2 \Rightarrow \dots \Rightarrow w$ je postupnosť krokov odvodení. Pod **ľavým**, resp. **pravým krajným odvodením** rozumieme odvodenie, v ktorom sa v každom kroku odvodenia, v ktorom máme viacero neterminálov, ktoré sa dajú prepisovať, vždy prepíše *najľavejší*, resp. *najpravejší* neterminál.

3.1.2 Syntaktická analýza

Na to, aby sme vedeli preložiť Datalog do relačnej algebry potrebujeme vedieť identifikovať a preložiť jeho jednotlivé jazykové prvky. Tie prvky nájde tzv. *syntaktická analýza*. Ukážeme si, ako funguje na jednoduchom príklade, v ktorom budeme prekladať aritmetické výrazy z infixovej notácie do postfixovej notácie.

Zoberme si jednoduchú gramatiku G generujúcu jazyk aritmetických výrazov v

infixovej notácii:


$G = (N, T, P, \sigma)$, kde

$N = \{\sigma, \alpha\}$,


$T = \{+, \cdot, (,), 0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$,

$P = \{\sigma \rightarrow (\sigma) \mid \sigma + \sigma \mid \sigma \cdot \sigma \mid 1\alpha \mid 2\alpha \mid 3\alpha \mid 4\alpha \mid 5\alpha \mid 6\alpha \mid 7\alpha \mid 8\alpha \mid 9\alpha \mid 0,$
 $\alpha \rightarrow 0\alpha \mid 1\alpha \mid 2\alpha \mid 3\alpha \mid 4\alpha \mid 5\alpha \mid 6\alpha \mid 7\alpha \mid 8\alpha \mid 9\alpha \mid \varepsilon\}.$

Zoberme si slovo z tohto jazyka, napríklad $(4 + 5) \cdot 123 \cdot 0$, a k nemu jedno príslušajúce odvodenie (odvodenie zakreslíme pomocou stromu).



Pravé krajné odvodenie



Ľavé krajné odvodenie

Môžeme si všimnúť, že veľkosť stromu odvodu rýchlo narastá, hlavne kvôli odvodzovaniu čísiel. Preto sa v praxi často používa tzv. *lexer* (*tokenizer*). Lexer rozdelí vstupný reťazec (slovo) na tzv. *tokens*, ktoré sú zjednodušenou reprezentáciou častí vstupného reťazca. Tieto tokeny sú popísané pomocou regulárnych jazykov (väčšinou pomocou regulárnych výrazov, ktoré sú ekvivalentné s regulárnymi gramatikami [7]). Následne sa odvodenie robí nad tokenami, čím sa zmenší veľkosť stromu odvodu a zjednoduší sa nám odvodenie. V našom prípade definujeme jeden token reprezentujúci celé čísla

$$\text{INT} = \{0\} \cup \{1, 2, 3, 4, 5, 6, 7, 8, 9\} \cdot \{1, 2, 3, 4, 5, 6, 7, 8, 9, 0\}^* \approx \mathbb{N}_0.$$

Lexer pri čítaní vstupného reťazca postupne rozpoznáva jednotlivé tokeny podľa definovaných regulárnych výrazov. Napríklad pri spracovaní reťazca $(4 + 5) \cdot 123 \cdot 0$ by lexer generoval nasledujúci *stream tokenov*:


LPAREN($()$), INT(4), PLUS(+), INT(5), RPAREN($()$), MULT($\cdot$), INT(123), MULT($\cdot$), INT(0)

Každý token obsahuje svoj typ (INT, PLUS, LPAREN, ...) a prípadne svoju hodnotu. Táto sekvencia tokenov sa potom posiela parseru, ktorý na nej vykonáva syntaktickú analýzu.

Potom sa gramatika G zjednoduší na


$$\begin{aligned} G' &= (N', T', P', \beta), \text{ kde} \\ N' &= \{\beta\}, \\ T' &= \{+, \cdot, (,), \text{INT}\}, \\ P' &= \{\beta \rightarrow (\beta) \mid \beta + \beta \mid \beta \cdot \beta \mid \text{INT}\}. \end{aligned}$$

Ľavé krajné odvodenie slova $(4 + 5) \cdot 123 \cdot 0$ v gramatike G' by vyzeralo nasledovne:




Ľavé krajné odvodenie v gramatike G'

Na takýto strom odvodu môžeme aplikovať algoritmus, ktorý nám z infixovej notácie vygeneruje postfixovú notáciu. Algoritmus funguje nasledovne: vrcholy stromu (odvodu) sa transformujú podľa nasledujúcich pravidiel:



Po aplikovaní týchto pravidiel na strom odvodu dostaneme strom reprezentujúci postfixovú notáciu, z ktorého vieme jednoducho vygenerovať výsledný výraz.



Odvodenie slova $45 + 123 \cdot 0$.

Problém nastáva, ako zo vstupného slova vygenerovať strom odvodu. Na tento problém existuje viacero algoritmov, ktoré sa líšia v tom, akú množinu gramatík dokážu spracovať. Jeden z týchto algoritmov je tzv. $LL(k)$ algoritmus, ktorý číta vstup zľava doprava (**L**eft to **r**ight) a vytvára ľavé krajné odvodenie (**L**eftmost derivation) a pozerá sa na k nasledujúcich tokenov.

ANTLR je generátor parserov, ktorý na základe gramatiky, ktorú mu zadáme, vygeneruje parser (a lexer), ktorý dokáže pomocou $LL(k)$ algoritmu zistiť, či dané slovo patrí do jazyka generovaného touto gramatikou a v prípade, že áno, vygeneruje k nemu prislúchajúci strom ľavého krajného odvodu.

3.2 Gramatika Datalogu pre ANTLR

Program ANTLR potrebuje na vygenerovanie parseru gramatiku Datalogu. V tejto kapitole ju zostrojíme a odôvodníme, prečo sme zvolili práve takúto gramatiku.

ANTLR používa iný zápis pravidiel gramatiky ako sme definovali v teoretickej časti. Napríklad pravidlo $\sigma \rightarrow w_1 \mid w_2$ sa zapíše v ANTLR ako `sigma: w1 | w2;`. Terminály sa píšú do jednoduchých úvodzoviek, napríklad `'('`. Tokeny sa píšú veľkými písmenami, napríklad `NUMBER`. Užitočným rozšírením je možnosť použiť zátvorky na zoskupovanie, napríklad `(w_1 | w_2)`, čo znamená, že sa môže použiť buď w_1 alebo w_2 , `(w)*` znamená, že w sa môže použiť nula alebo viackrát a `(w)+` znamená, že w sa musí použiť aspoň raz. Viac o zápise gramatiky v ANTLR sa dočítate v dokumentácii [1].

Datalogový program (teória s dotazom) sa skladá z niekoľkých klauzúl (niektoré z nich môžu byť faktami), nasledovaných dotazom. Do gramatiky (pre ANTLR) to prepíšeme ako

```
program: (clause | definition)* query;
```

kde `program` bude počiatočný neterminál celej gramatiky, `clause`, resp. `definition`, resp. `query` bude neterminál, z ktorého sa odvodí klauzula, resp. definícia, resp. dotaz. Takto definovaná gramatika vyžaduje práve jeden dotaz na konci programu, ale môže obsahovať ľubovoľný počet klauzúl a definícií (vrátane žiadnych).

Neterminál `definition` sa bude prepisovať priamočiaro. Najprv treba zadať meno predikátu, ktorý definujeme a potom napísať n -tice termov, pre ktoré je platný.

```
definition: name BODY_HEAD_SEPARATOR '{' '}' EOL |
           name BODY_HEAD_SEPARATOR '{'
           term_tuple (',' term_tuple)*
           '}' EOL;
```

```
term_tuple: '(' ')' |
           '(' term (',' term)* ')';
```

Neterminál `clause` bude trochu komplikovanejší, pretože musí obsahovať hlavu a telo klauzuly. V tele klauzuly sa môžu vyskytovať predikáty, negované predikáty, ale aj vstavané predikáty a negované vstavané predikáty.

```

clause: name '(' ')' BODY_HEAD_SEPARATOR
        (predicate | built_in_predicate)
        (',' (predicate | built_in_predicate))* EOL |
name '(' term (',' term)* ')' BODY_HEAD_SEPARATOR
        (predicate | built_in_predicate)
        (',' (predicate | built_in_predicate))* EOL;

predicate:      normal_predicate |
               negative_predicate;
negative_predicate: NOT normal_predicate;

built_in_predicate:      normal_built_in_predicate |
                        negative_built_in_predicate;
negative_built_in_predicate: NOT normal_built_in_predicate;

```

Normálny vstavaný predikát sa skladá z mena a z n -tice termov, rovnako ako hlava klauzuly.

```

normal_predicate: name '(' ')' |
                 name '(' term (',' term)* ')';

```

Vstavaný predikát je podobný normálnemu predikátu, až na to, že jeho parametre môžu byť nielen termy, ale aj predikáty a vstavané predikáty, ktoré môžu byť rôzne usporiadané v zoznamoch.

```

normal_built_in_predicate: BUILT_IN name '(' ')' |
                           BUILT_IN name '('
                               parameter (',' parameter)*
                           ')';

parameter: '[' ']' |
          '[' parameter (',' parameter)* ']' |
          normal_predicate |
          normal_built_in_predicate |
          term;

```

Token `BUILT_IN` by sme mohli vynechať. V takom prípade by ale kompilátor nevedel rozlíšiť vstavané predikáty od normálnych predikátov. To by pri následnom preklade do relačnej algebry znamenalo, že každý predikát, čo nebol definovaný faktom alebo klauzulou, by sa musel považovať za vstavaný predikát. Keďže ale chceme, aby kompilátor vedel fungovať samostatne, bez prístupu do *databázy* , nevieme, ktoré vstavané

predikáty sú v databáze k dispozícii. Kvôli tomu by sme nevedeli vyhodiť kompilačnú chybu, keď v klauzule použijeme nedefinovaný predikát.

Keďže povoľujeme iba kladné dotazy, tak **query** sa môže prepísať iba na normálny predikát, obyčajný alebo vstavany.

```
query: QUERY_MARKER (normal_predicate | normal_built_in_predicate) EOL;
```

Použité tokeny sú definované nasledovne, pričom [0-9] resp. [a-z] znamená ľubovoľný znak z množiny číslíc resp. písmen:

```
QUERY_MARKER: '?-';
BODY_HEAD_SEPARATOR: ':-' ;
SLC: '%';
MLC_START: '/*';
MLC_END: '*/';
EOL: ' ';
NOT: '\\+';
BUILT_IN: '$';

UPPER: [A-Z]+;
LOWER: [a-z]+;
NUMBER: [0-9]+;
```

Tento prístup umožňuje jednoducho zmeniť detaily syntaxe, ak sa ich používateľ neskôr rozhodne zmeniť. Napríklad, ak by chcel pre $\leftarrow$ používať alternatívny zápis $<-$, stačí zmeniť definíciu tokenu `BODY_HEAD_SEPARATOR = '<-' ;`.

Názvy predikátov a funkčných symbolov sa skladajú z malých písmen, čísiel a znaku `_`. Premenné budú rovnaké, ale budú sa skladať z veľkých písmen. Všetky názvy sa musia začať písmenom.

```
name: LOWER (LOWER | NUMBER | '_')*;
function: LOWER (LOWER | NUMBER | '_')*;
variable: UPPER (UPPER | NUMBER | '_')*;
```

Na koniec ešte ANTLR nastavíme, aby preskakoval *whitespace* znaky a podporoval jednoriadkové aj viacriadkové komentáre.

```
WS: [ \t\r\n]+ -> skip;
COMMENT: SLC ~[\n\r]* ([\n\r] | EOF) -> channel(HIDDEN);
MULTILINE_COMMENT: MLC_START (MULTILINE_COMMENT | .)*?
                    (MLC_END | EOF) -> channel(HIDDEN);
```

3.3 Algoritmus prekladu

Po vygenerovaní stromu odvedenia prichádza na rad preklad do relačnej algebry. Preklad sa realizuje v piatich krokoch.

V prvom kroku využijeme dva objekty, ktoré nám automaticky vygeneroval ANTLR. Najprv vytvoríme objekt `datalogLexer`, ktorý potom premeníme na `CommonTokenStream`. Tento druhý objekt je v podstate zoznam tokenov, ktoré sa vyskytujú v zdrojovom kóde. Formálne by to boli znaky (resp. písmená) slova, z ktorých hľadáme strom odvedenia.

```
CharStream program;
datalogLexer lexer = new datalogLexer(program);
CommonTokenStream tokens = new CommonTokenStream(lexer);
```

V druhom kroku vytvoríme objekt `datalogParser` (ktorý tiež vygeneroval ANTLR), ktorý nám umožní pracovať s gramatikou, ktorú sme definovali v súbore `datalog.g4`. Tento objekt nám umožní vytvoriť strom odvedenia z tokenov, ktoré sme získali v prvom kroku.




```
datalogParser parser = new datalogParser(tokens);
ParseTree tree = parser.program();
```


3.3.1 Generácia AST

Tretí krok je zavolanie objektu `DatalogASTBuilder`, ktorý nám transformuje strom odvedenia na abstraktný syntaktický strom (AST). Tento strom je jednoduchší a pohodlnejší na ďalšie spracovanie. Transformácia sa realizuje pomocou tzv. *visitor patternu*. Vstupom je objekt typu `DatalogProgram`, ktorý obsahuje všetky definície, klauzuly a dotaz. Triedy, ktoré sa týkajú AST, sú definované v priečinkoch `datalog` a `common` (spoločné objekty pre `datalog` aj relačnú algebru, termy a parametre).

```
DatalogASTBuilder astBuilder = new DatalogASTBuilder();
DatalogProgram ast = (DatalogProgram) astBuilder.visit(tree);
```


Príkladom, aká transformácia sa deje, je transformácia na objekty typu `Atom` a `Predicate`. Všetky nasledujúce podstromy odvedenia sa transformujú na rovnaké objekty s rovnakým rozhraním.

*Obyčajný predikát**Negovaný obyčajný predikát**Vstavaný predikát*



Negovaný vstavaný predikát

Celá štruktúra a hierarchia tried, ktoré reprezentujú AST, sú podrobnejšie popísané v nasledujúcom diagrame.



Hierarchia tried AST

V tejto fáze sa tiež realizuje kontrola, či sú klauzuly bezpečné a či všetky `term_tuple` v definícii majú rovnakú aritu, keďže tieto vlastnosti programu nie je

možné vyjadriť pomocou bezkontextovej gramatiky. Taktiež sa kontroluje, či termy v `term_tuple` neobsahujú premenné (táto vlastnosť by sa síce dala vyjadriť bezkontextovou gramatikou, ale uvedený postup je jednoduchší).

3.3.2 Preklad do relačnej algebry

Posledné 2 kroky sa týkajú samotného prekladu do relačnej algebry a vykonáva ich trieda `DatalogCompiler`.

```
DatalogCompiler compiler = new DatalogCompiler();
RAExpr compiled = compiler.compile(ast);
```

V štvrtom kroku vygenerujeme pre každý predikát v programe objekt typu `RAExpr`, ktorý reprezentuje reláciu k nemu prislúchajúcu. Ak je nejaký predikát závislý na inom predikáte, zatiaľ ho nepreložíme, ale použijeme referenciu (*placeholder*) na tento predikát (objekt typu `RelationRef`). Prekladať nebudeme priamo do relačnej algebry, ale do Java objektov reprezentujúcich relačnú algebru. To nám umožní ľahšie manipulovať s výsledným výrazom a taktiež jednoduchšie meniť zápis výsledného výrazu. Napríklad ak by sme chceli zmeniť poradie parametrov v operátoroch, alebo zmeniť odsadenie a zátvorky.

Prvým problémom, s ktorým sa v tomto kroku stretávame, je ako preložiť definície. Definície sú v podstate relácie, ktoré obsahujú pevne dané množiny n -tíc. Keďže nemáme žiaden operátor, ktorý by toto priamo podporoval, musíme „zneužiť“ operátor **JOIN** a vstavané relácie.

Definícia 3.3.1. Vstavané relácie $\$true$ a $\$false$ sú definované nasledovne:

$$\begin{aligned}\$true &= \{()\} \\ \$false &= \emptyset\end{aligned}$$

Zoberme si výraz **JOIN**($[\$true]$, $[[[]], [n1(), a()]]$) (normálne by sme zapísali konštanty ako 1 a a , ale naša aktuálna implementácia vyžaduje tento zápis). Nech M je množina z definície **JOIN**. Potom $M = \{()\}$, keďže iba pre $()$ platí $() \in \$true$. Zápis je trochu neintuitívny, ale robí čo potrebujeme. Výsledná relácia R je rovná $\{(n1(), a())\}$.

Týmto spôsobom vieme vyrobiť ľubovoľnú reláciu s jednou n -ticou. Pre viacnásobné n -tice môžeme použiť viacnásobné **JOIN** obalené v **UNION**.

Program (resp. iba časť programu) `color :- {(red()), (blue())}`. sa preloží ako

```
UNION([
    JOIN([$true], [[]], [red()]),
    JOIN([$true], [[]], [blue()])
])
```

Príklad 3.1

Keďže jeden predikát môže byť definovaný viackrát, musíme prejsť všetky definície, pozbierať všetky n-tice a spojiť ich do jednej relácie (bez duplikátov).

Pôvodne sme chceli mať v relačnej algebre aj operátor **DEF**, ktorý by nám umožňoval definovať reláciu pomocou množiny n-tíc. Preto sa používa v programe kompilátora trieda **RADef**. Keďže sme sa ale nakoniec rozhodli uprednostniť menšiu množinu operátorov, **DEF** sa transformuje na **UNION JOIN**-ov, ako sme ukázali v príklade vyššie. Preto sa v tejto fáze realizuje aj táto transformácia.

Druhým problémom je preklad klauzúl. V Datalogu je klauzula v podstate konjunkcia atómov a keďže konjunkcia je asociatívna a komutatívna, môžeme atómy v klauzule zoradiť ľubovoľne. Preto môžeme pred prekladom klauzúl zoradiť atómy tak, že najprv budú kladné atómy a až potom negované atómy.

Z kladných atómov vieme pomocou **JOIN** vyrobiť reláciu, ktorá obsahuje všetky n-tice, ktoré môžeme doplniť, aby boli všetky pravdivé. Túto výslednú reláciu potom použijeme ako prvú reláciu v **ANTIJOIN** operátore, pomocou ktorého odfiltrujeme všetky n-tice, ktoré by spĺňali negované atómy. Výstupom celej klauzuly sú ale iba tie n-tice, ktoré spĺňajú hlavu klauzuly. To zohľadníme vo výstupnom vektore v **ANTIJOIN**-e (respektíve v **JOIN**-e, ak nemáme negatívne atómy).

Časť Datalogového programu

```
dvojica(f(A), D) :- $hrana(A, B),
                    $hrana(f(B), kon()),
                    $hrana(kon(), D),
                    \+ $hrana(A, kon()),
                    \+ $hrana(f(B), D).
```

sa preloží nasledovne. Najprv vytvoríme reláciu z kladných atómov pomocou **JOIN**-u.

```
JOIN(
    [$hrana, $hrana, $hrana],
```

```

    [[A, B], [f(B), kon()], [kon(), D]],
    [A, B, D]
)

```

Táto relácia obsahuje všetky n -tice, ktoré spĺňajú kladné atómy. Potom použijeme **ANTIJOIN** na vytvorenie výslednej relácie dvojica.

```

ANTIJOIN(
  [JOIN(
    [$hrana, $hrana, $hrana],
    [[A, B], [f(B), kon()], [kon(), D]],
    [A, B, D]
  ),
  $hrana, $hrana],
  [[A, B, D], [A, kon()], [f(B), D]],
  [f(A), D]
)

```

Príklad 3.2

V prípade, že klauzula neobsahuje žiadne negované atómy, použijeme iba **JOIN** a výstupný vektor bude zodpovedať hlave klauzuly. V prípade, že klauzula obsahuje iba jeden pozitívny atóm, **JOIN** nie je potrebné vyrábať, ale môžeme použiť tento atóm priamo v **ANTIJOIN**-e.

Zaujímavý prípad je klauzula, ktorá obsahuje iba negované atómy. Keďže musí byť bezpečná, nemôže obsahovať žiadne premenné, ale iba konštanty. V takomto prípade má klauzula tvar „ n -tica 1 patrí do relácie A , ak n -tica 2 nepatrí do relácie B , n -tica 3 nepatrí do relácie C , ...“. Keďže ale **ANTIJOIN** potrebuje jednu reláciu v pozitívnom kontexte, musíme do všetkých takýchto klauzúl pridať nejaký pozitívny atóm, napríklad **\$true()**.

Klauzula **test(n1()) :- \+ \$a(n2()), \+ \$b(n3())**. sa preloží ako:

```
ANTIJOIN([$true, $a, $b], [[], [n2()], [n3()]], [n1()])
```

Príklad 3.3

V prípade, že jeden predikát je definovaný viackrát, musíme všetky klauzuly, ktoré mu prislúchajú, spojiť do jednej relácie pomocou **UNION**-u.

Program

```
p(X) :- $a(X).
p(Y) :- $b(Y).
```

sa preloží ako:

```
UNION([
    JOIN([$a], [[X]], [X]),
    JOIN([$b], [[Y]], [Y])
])
```

Príklad 3.4

Výsledkom štvrtého kroku je teda mapa `Map<String, RAExpr>`, ktorá priradzuje každému predikátu (resp. relácii) výraz v relačnej algebre, ktorý ho reprezentuje. Ak sa v niektorej relácii vyskytuje referencia na iný predikát, táto referencia je zatiaľ nevyplnená (je to objekt typu `RelationRef`).

Poznámka 3.3.1. Teoreticky nezáleží od poradia atómov v klauzule, ale pri konkrétnych vstavaných predikátoch môže záležať. Zoberme si napríklad predikát `$plus(X, Y, Z)`, ktorý je pravdivý vtedy a len vtedy, keď $X + Y = Z$. Jeho implementácia v databázovom systéme môže byť taká, že ak sú zadané (sú konštanty) X a Y , vráti Z (Z je premenná) alebo ak sú zadané X , Y a Z , vráti pravdivostnú hodnotu a to je všetko. Aktuálna implementácia napr. **JOIN**-u v našom databázovom systéme je ale nasledovná. Zoberie sa prvá relácia a jej vstupný vektor. Vyberie sa z nej nejaká n -tica, aby spĺňala vstupný vektor. Týmto sa môžu konkretizovať niektoré premenné. Potom sa zoberie druhá relácia a jej vstupný vektor (s už konkretizovanými premennými) a spraví sa to isté. Preto v našom prípade záleží od poradia atómov. Ako príklad si zoberme program

```
p(Z) :- $cisloDo10(X), $cisloDo10(Y), $plus(X, Y, Z).
```

Príslušný výraz v relačnej algebre je

```
JOIN(
    [$cisloDo10, $cisloDo10, $plus],
    [[X], [Y], [X, Y, Z]],
    [Z]
)
```

Sémanticky identický program

```
p(Z) :- $plus(X, Y, Z), $cisloDo10(X), $cisloDo10(Y).
```


sa ale preloží ako

```
JOIN(
    [$plus, $cisloDo10, $cisloDo10],
    [[X, Y, Z], [X], [Y]],
    [Z]
)
```

a tento výraz nemusí byť správne vyhodnotený, keďže *plus* nemusí vedieť pracovať s tromi premennými.

Preto si používateľ musí dávať pozor na to, v akom poradí píše atómy do klauzúl, keďže to môže ovplyvniť vypočítateľnosť dotazu. Náš kompilátor zoberie najprv kladné atómy v poradí a následne negované atómy v poradí v akom boli zapísané v programe.

V piatom kroku tieto referencie nahradíme výrazom, ktorý im prislúcha. Keďže ale môže nastať situácia, že niektorý predikát je závislý sám na sebe (priamo alebo nepriamo), musíme prípadne predikáty *zabaliť* do rekurzívneho operátora **REC**. To spravíme tak, že najprv skonštruujeme graf závislosti predikátov, v ktorom bude orientovaná hrana z predikátu *A* do predikátu *B*, ak *A* (priamo) závisí na *B*. Potom pre každý predikát skontrolujeme, či existuje cesta z neho do seba samého. Ak áno, tento predikát je rekurzívny a musíme ho zabaliť do **REC**.

Výsledný výraz v relačnej algebre začneme stavať od dotazu. Prechádzame jeho výraz do hĺbky a pamätáme si, cez aké **REC** operátory sme prešli. Keď narazíme na **RelationRef** (pre ktorý sme nevideli operátor **REC**), nahradíme ho výrazom, ktorý mu prislúcha. Takto postupujeme, až kým nenahradíme všetky **RelationRef** výrazmi, ktoré im prislúchajú. Výsledkom ale nemá byť celá relácia, ale iba tie záznamy, ktoré spĺňajú hlavu dotazu. Preto ešte celý výsledný výraz zabalíme do **JOIN**-u, ktorého výstupný vektor bude zodpovedať hlave dotazu.

Ukážeme si preklad programu spolu s vysvetlením, ktoré časti relačnej algebry zodpovedajú ktorým častiam programu.

```
1 node :- {(a()), (b()), (c())}.
2 blocked :- {(c())}.
3
4 reachable(X) :- node(X).
5 reachable(X) :- reachable(X).
6
7 selected(X) :- reachable(X), $eq(X, b()).
8 free(X) :- reachable(X), \+ blocked(X).
9
```

```

10 result(X) :- free(X), selected(X).
11
12 ?- result(Z).

```

Znak % označuje jednoriadkový komentár.

```

JOIN([                                     % dotaz - 12
  JOIN([                                   % result - 10
    ANTIJOIN([                             % free - 8
      REC(reachable,                       % lebo riadok 5 je rekurzívny
        UNION([
          JOIN([                             % reachable - 4
            UNION([                         % node - 1
              JOIN([$true], [[]], [a()]),
              JOIN([$true], [[]], [b()]),
              JOIN([$true], [[]], [c()])
            ])
          ], [[X]], [X]),
          JOIN([reachable], [[X]], [X])    % reachable - 5
        ])
      ),
      JOIN([$true], [[]], [c()])          % blocked - 2
    ], [[X], [X]], [X]),
    JOIN([                                 % selected - 7
      REC(reachable,                       % znovu reachable
        UNION([
          JOIN([
            UNION([
              JOIN([$true], [[]], [a()]),
              JOIN([$true], [[]], [b()]),
              JOIN([$true], [[]], [c()])
            ])
          ], [[X]], [X]),
          JOIN([reachable], [[X]], [X]])
        ),
        $eq
      ], [[X], [X, b()]], [X])
    ], [[X], [X]], [X])
  ], [[Z]], [Z])

```

Rekapitulácia

Preklad do relačnej algebry sa realizuje v piatich krokoch. Heslovite sú to:

1. Vytvorenie lexeru a token streamu
2. Vytvorenie parseru a stromu odvodenia
3. Generácia AST z odvodenia
4. Preklad predikátov do relačnej algebry s nevyplnenými referenciami
 - (a) Preklad definícií pomocou **JOIN** a **UNION**
 - (b) Preklad klauzúl pomocou **JOIN** a **ANTIJOIN**
 - (c) Spojenie klauzúl do jednej relácie pomocou **UNION**
5. Zostavenie výsledného výrazu v relačnej algebre
 - (a) Zostavenie grafu závislosti predikátov
 - (b) Zabalenie rekurzívnych predikátov do **REC**
 - (c) Nahradenie referencií výrazmi, ktoré im prislúchajú
 - (d) Zabalenie výsledného výrazu do **JOIN**-u reprezentujúceho dotaz

Záver

Cieľom tejto bakalárskej práce bolo rozšíriť náš experimentálny databázový systém o ďalší dotazovací jazyk, konkrétne o Datalog s funkčnými symbolmi a vstavanými predikátmi, a implementovať kompilátor, ktorý bude tento jazyk prekladať do relačnej algebry. Zároveň sme chceli, aby bol výsledný kompilátor použiteľný aj samostatne, bez priamej väzby na konkrétnu databázovú implementáciu. Tento cieľ sa podarilo splniť.

V práci sme najprv zaviedli potrebné teoretické základy datalogu, vysvetlili jeho sémantiku a ukázali, aké úpravy sú potrebné na podporu funkčných symbolov a vstavaných predikátov. Dôležitou časťou bolo aj spresnenie požiadaviek na cieľovú relačnú algebru, čo viedlo k jej predefinovaniu a rozšíreniu o nové operátory.

Na tomto základe sme navrhli gramatiku jazyka pre ANTLR, spôsob reprezentácie programu pomocou AST a samotný viacstupňový algoritmus prekladu do relačnej algebry. Výsledkom je riešenie, ktoré vykonáva nielen syntaktickú analýzu, ale aj základnú sémantickú kontrolu programu a následne konštruuje ekvivalentný výraz relačnej algebry.

Výsledkom práce je kompilátor, ktorý umožňuje používateľovi formulovať dotazy v rozšírenom Datalogu, ktorý je prirodzenejší a stručnejší, pričom výsledný výraz relačnej algebry je generovaný automaticky. Týmto sme dosiahli cieľ, ktorý sme si stanovili, a zároveň sme vytvorili nástroj, ktorý môže byť ďalej rozšírený a integrovaný do rôznych databázových systémov.

Pri práci sa tiež ukázalo niekoľko obmedzení súčasného riešenia. Poradie atómov v klauzulách môže ovplyvniť vypočítateľnosť programu, čo môže viesť k neočakávaným výsledkom. Taktiež riešenie predpokladá existenciu vstavanej relácie *\$true*. V budúcnosti by bolo možné tieto obmedzenia odstrániť, napríklad zavedením nového operátora na vytvorenie relácie alebo pridaním možnosti ovplyvniť poradie operátorov v generovanom výraze relačnej algebry.

Literatúra

- [1] ANTLR Project. Antlr 4 documentation. <https://github.com/antlr/antlr4/blob/master/doc/index.md>, 2026. [Online; navštívené 21. apríla 2026].
- [2] Diana Biriukova. Compiler of relational algebra expressions, 2025.
- [3] Matúš Hedera. Relačná algebra pre výpočet rekurzívnych dotazov, 2022.
- [4] Tomáš Magát. Návrh a implementácia operátorov relačnej algebry, 2026.
- [5] Tomáš Plachetka and Ján Štunc. Semantics of queries. Prednáškové slajdy ku kurzu Databases, Fakulta matematiky, fyziky a informatiky Univerzity Komenského v Bratislave, February 2026. Summer 2025–2026. Dostupné na: <http://www.dcs.fmph.uniba.sk/~plachetk/TEACHING/RLDB2026/index.html>.
- [6] Branislav Rován and Michal Forišek. Definície. Vo: Formálne jazyky a automaty, 2013. s. 7. – 12. FMFI UK, Bratislava.
- [7] Branislav Rován and Michal Forišek. Regulárne výrazy. Vo: Formálne jazyky a automaty, 2013. s. 28. FMFI UK, Bratislava.
- [8] Branislav Rován and Michal Forišek. Syntaktická analýza. Vo: Formálne jazyky a automaty, 2013. s. 102. – 114. FMFI UK, Bratislava.
- [9] Soufflé Language Team. Soufflé: Program translation. <https://souffle-lang.github.io/translate>, 2024. [Online; navštívené 7. januára 2026].
- [10] Allen Van Gelder, Kenneth A. Ross, and John S. Schlipf. The well-founded semantics for general logic programs. *Journal of the ACM*, 38(3):620–650, July 1991.

Príloha

Štruktúra priečinka compiler

```
compiler/
├── generate_tests.sh
├── pom.xml
├── README.md
├── src/
│   ├── main/
│   │   ├── antlr4/
│   │   │   └── datalog.g4
│   │   └── java/
│   │       ├── common/
│   │       │   ├── Constant.java
│   │       │   ├── FunctionTerm.java
│   │       │   ├── Parameter.java
│   │       │   ├── Term.java
│   │       │   └── Variable.java
│   │       ├── datalog/
│   │       │   ├── Atom.java
│   │       │   ├── Clause.java
│   │       │   ├── DatalogProgram.java
│   │       │   ├── Definition.java
│   │       │   ├── Predicate.java
│   │       │   └── Query.java
│   │       └── ra/
│   │           ├── RAAntiJoin.java
│   │           ├── RADef.java
│   │           ├── RAExpr.java
│   │           ├── RAJoin.java
│   │           ├── RARec.java
│   │           ├── RAUnion.java
│   │           └── RelationRef.java
│   │       ├── DatalogASTBuilder.java
│   │       ├── DatalogCompiler.java
│   │       ├── MyErrorListener.java
│   │       └── TranslateDatalogFile.java
└── tests/
    ├── 000_turing_machine.dl
    ├── 000_turing_machine.ra
    └── ...
```

Súbory s príponou `.dl` sú vstupné testovacie Datalogové programy. Súbory s príponou `.ra` obsahujú očakávaný výstup prekladu v relačnej algebre. Testy označené ako *chybový vstup* (prípona `_e`) neobsahujú súbor `.ra`, pretože ich očakávaným výsledkom je chybová hláška kompilátora.

Súbor `TranslateDatalogFile.java` obsahuje metódu `main`, ktorá preloží Datalogový program zo štandardného vstupu a vypíše výsledok na štandardný výstup.

Súbor `generate_tests.sh` je skript, ktorý pre každý Datalogový program v priečinku `tests` spustí kompilátor, presmeruje ho na štandardný vstup a výstup presmeruje do príslušného súboru `.ra`.

Súbor `datalog.g4` obsahuje gramatiku Datalogu, ktorú používa nástroj ANTLR na vygenerovanie Java kódu pre lexikálnu a syntaktickú analýzu Datalogových programov.

Súbor `README.md` obsahuje stručný popis priečinka a návod na spustenie kompilátora a testov.